

Diseño ETL: Movimientos de inventario - WWImporters

Dim_Proveedor	Dim_TipoTransaccion	Dim_Fecha	Hecho_Movimiento
Fuente de datos: proveedores, CategoriasProveedores Campos a incluir: proveedores: ProveedorID, NombreProveedor, CategoriaProveedorID, PersonaContactoPrincipalID, DiasPago, CódigoPostal. Campos No incluidos: Columnas de proveedores no requeridas (cuentas de banco, fax, comentarios, CódigoPostal2, etc.).	Fuente de datos: TiposTransaccion Campos a incluir: TipoTransaccionID, TipoTransaccionNombre Campos No incluidos: Ninguno (la tabla solo tiene id y nombre).	Fuente de datos: movimientos (columna FechaTransaccion) Campos a incluir: FechaTransaccion (de movimientos). Campos No incluidos: Los demás campos de movimientos (se usan en el hecho, no en la dimensión Fecha).	Fuente de datos: movimientos (+ dimensiones ya cargadas: Producto, Cliente, Campos a incluir: ProductoID, ClienteID, ProveedorID, TipoTransaccionID, FechaTransaccion, Cantidad Campos No incluidos: TransaccionProductoID, InvoiceID, OrdenDeCompraID (no requeridos por el modelo).
1. Extraer información de proveedores y CategoriasProveedores 2. Transformaciones Transf 1. Unir proveedores con CategoriasProveedores (left join por CategoriaProveedorID) para traer CategoriaProveedor. Transf 2. Corregir DiasPago negativos multiplicándolos por -1 (no pueden ser negativos). Transf 3. Unificar en un solo proveedor las filas duplicadas con el mismo nombre + sufijo "Inc"/"Ltd" (error de digitación). Transf 4. Corregir el CódigoPostal (era el mismo para todos los proveedores; dato erróneo). Transf 5. Renombrar ProveedorID → ID_Proveedor_T y generar ID_Proveedor_DWH (monotonically_increasing_id + 1). Transf 6. Agregar el registro comodín ID = 0 ("sin dato"). 3. Carga de los datos Destino de los datos: Proveedor (bodega DB_2025...) Campos a cargar: ID_Proveedor_DWH, ID_Proveedor_T, Nombre, Categoria, Contacto_principal, Dias_pago, Código_postal	1. Extraer información de TiposTransaccion 2. Transformaciones Transf 1. La tabla TiposTransaccion ya fue analizada por el grupo de consultores; se usa tal cual. Transf 2. Renombrar TipoTransaccionID → ID_Tipo_transaccion_T y TipoTransaccionNombre → Tipo. Transf 3. Generar ID_Tipo_transaccion_DWH (monotonically_increasing_id + 1). Transf 4. Agregar el registro comodín ID = 0 ("sin dato"). 3. Carga de los datos Destino de los datos: TipoTransaccion (bodega DB_2025...) Campos a cargar: ID_Tipo_transaccion_DWH, ID_Tipo_transaccion_T, Tipo	1. Extraer información de movimientos (FechaTransaccion) 2. Transformaciones Transf 1. Extraer las fechas distintas (FechaTransaccion, tipo text), incluyendo los años anteriores a 2014 (su ausencia previa era un error de extracción ya corregido). Transf 2. Estandarizar el formato: YYYY-MM-DD HH:MM:SS cuando hay hora; de lo contrario, YYYY-MM-DD. Transf 3. Derivar los atributos Día, Mes, Año y Numero_semana_ISO. Transf 4. Generar ID_Fecha como entero YYYYMMDD y dejar Fecha en tipo Date. Transf 5. Agregar el registro comodín ID = 0 ("sin dato"). 3. Carga de los datos Destino de los datos: Fecha (bodega DB_2025...) Campos a cargar: ID_Fecha, Fecha, Día, Mes, Año, Numero_semana_ISO	1. Extraer información de movimientos (transacciones de inventario) 2. Transformaciones Transf 1. Eliminar las filas totalmente duplicadas (dropDuplicates): el negocio indicó no considerar los duplicados totales. Transf 2. No aplicar la antigua regla de "máx. 50 millones por transacción" (eliminada por el negocio). Transf 3. Mantener las cantidades negativas: representan salidas de productos del inventario (no se eliminan). Transf 4. Estandarizar FechaTransaccion y derivar ID_Fecha (YYYYMMDD) para el cruce con Dim_Fecha. Transf 5. Lookup (left join) a cada dimensión por su llave de negocio (T) para traer las llaves surrogate (DWH): Producto (ProductoID), Cliente (ClienteID), Proveedor (ProveedorID), TipoTransaccion (TipoTransaccionID), Fecha. Usar el comodín ID = 0 cuando no haya coincidencia. Transf 6. Seleccionar las llaves foráneas (DWH) + la medida Cantidad. 3. Carga de los datos Destino de los datos: Hecho_Movimiento (bodega DB_2025...) Campos a cargar: ID_Fecha, ID_Producto_DWH, ID_Proveedor_DWH, ID_Cliente_DWH, ID_Tipo_transaccion_DWH, Cantidad

Descripción general del diseño ETL.

El proceso ETL puebla cuatro objetos nuevos de la bodega a partir de la base transaccional WWImportersTransaccional: las dimensiones Proveedor, TipoTransaccion y Fecha, y la tabla de hechos Movimiento. Las dimensiones Producto y Cliente NO se procesan en este ETL porque son dimensiones compartidas (conformadas) que ya existen en la bodega gracias al proceso de Órdenes. Cada bloque sigue el flujo Extraer → Transformar → Cargar. Las transformaciones aplican las reglas de negocio entregadas por WWI: corregir los días de pago negativos (<-1), unificar los proveedores duplicados con sufijo Inc/Ltd, corregir el código postal erróneo, estandarizar el formato de fecha (YYYY-MM-DD HH:MM:SS a YYYY-MM-DD). Incluir los años anteriores a 2014, eliminar los duplicados totales y conservar las cantidades negativas (representan salidas de inventario; ya no aplica el tope de 50 millones). En cada dimensión se genera una llave surrogate (DWH) y se agrega un registro comodín ID = 0 para los casos sin dato; el hecho hace lookup (left join) a cada dimensión por su llave de negocio (T) para traer las llaves surrogate (DWH). Nota: nombres de origen verificados en WWImportersTransaccional — tablas proveedores, CategoriasProveedores, TiposTransaccion y movimientos (esta última en minúscula). La Fecha (FechaTransaccion) viene como texto y se estandariza en el ETL.

Tarea ETL — Proceso de Movimientos de inventario (WWImporters)

Entregable 2 — Descripción de la implementación y evidencias

Estudiante: Fabrizio Cucina | Bodega: DB_202613_f_cucina | Implementación en PySpark

1. Objetivo y alcance

El proceso ETL, implementado en PySpark, puebla en la bodega las dimensiones **Proveedor**, **TipoTransaccion** y **Fecha** y la tabla de hechos **Hecho_Movimiento**, a partir de la base transaccional **WWImportersTransactional**. Las dimensiones **Producto** y **Cliente** son conformadas (compartidas con el proceso de Órdenes); como en la bodega no estaban pobladas, se construyeron también desde la transaccional para permitir el cruce del hecho. Todas las tablas de esta tarea usan el sufijo **_t3** para no afectar las tablas de la tarea anterior.

2. Origen → destino

Dim_Proveedor ← proveedores + CategoríasProveedores

Dim_TipoTransaccion ← TiposTransaccion

Dim_Fecha ← movimientos.FechaTransaccion

Dim_Producto / Dim_Cliente ← Producto / Clientes (conformadas)

Hecho_Movimiento ← movimientos (+ lookup a todas las dimensiones)

3. Transformaciones aplicadas

Proveedor: unión con CategoríasProveedores para traer la categoría; días de pago negativos corregidos ($\times -1$); unificación de proveedores duplicados con sufijo Inc/Ltd; el código postal ya venía corregido de la fuente.

TipoTransaccion: se usa tal cual (ya analizada por consultores); solo renombrado al esquema de la bodega.

Fecha: estandarización del formato de fecha; inclusión de los años anteriores a 2014; derivación de Dia, Mes, Anio y Numero_semana_ISO; ID_Fecha como entero YYYYMMDD.

Hecho: eliminación de filas totalmente duplicadas; conservación de las cantidades negativas (salidas de inventario); sin el antiguo tope de 50 millones.

4. Generación de llaves y cruce del hecho

Cada dimensión genera su llave surrogada **_DWH** con `monotonically_increasing_id()+1` y un registro comodín **ID = 0** para los casos sin dato. El hecho cruza cada llave de negocio del origen (ProductoID, ClienteID, ProveedorID, TipoTransaccionID) con la llave **_T** de su dimensión para traer la **_DWH**; cuando no hay coincidencia, se asigna el comodín 0.

5. Aspectos técnicos resueltos


Driver JDBC: el conector MySQL (`drivers/mysql-connector-j.jar`) se carga al crear la SparkSession con la opción `spark.jars`.

Fechas en texto: FechaTransaccion llega como texto con fracción de segundos (p. ej. 2013-01-26 12:00:00.0000000); se habilitó `spark.sql.legacy.timeParserPolicy = LEGACY` para parsearla.

Tipos en el cruce: las llaves de movimientos llegan como bigint/double; se castearon a int (igual que las _T) y se usaron alias en los joins para evitar colisiones de nombres entre dimensiones.

6. Evidencias en la base de datos


Conteos de las tablas creadas y pobladas en la bodega, y la tabla de hechos resultante.



The screenshot shows a Jupyter Notebook interface with a file named 'tareas-modelado-datos-2026-13'. The active cell contains a SQL query: `SELECT COUNT(*) FROM DB_202613_f_cucina.Proveedor_t3;`. The output of the query is displayed in a table with one row and one column, showing the count of 14 records.

COUNT(*)
14


Conteo de Proveedor_t3 (14 registros).



The screenshot shows a Jupyter Notebook interface with a file named 'tareas-modelado-datos-2026-13'. The active cell contains a SQL query: `SELECT COUNT(*) FROM DB_202613_f_cucina.TipoTransaccion_t3;`. The output of the query is displayed in a table with one row and one column, showing the count of 13 records.

COUNT(*)
13


Conteo de TipoTransaccion_t3 (13 registros).



The screenshot shows a Jupyter Notebook interface with a file named 'tareas-modelado-datos-2026-13'. The active cell contains a SQL query: `SELECT COUNT(*) FROM DB_202613_f_cucina.Hecho_Movimiento_t3;`. The output of the query is displayed in a table with one row and one column, showing the count of 235753 records.

COUNT(*)
235753

Conteo de Hecho_Movimiento_t3 (235.753 registros).



Tablas de la bodega DB_202613_f_cucina: dimensiones y hecho de T3 (sufijo _t3).